

Silabus Kuliah: Analisis Big Data

Rencana perkuliahan 12 pertemuan untuk mahasiswa S1 semester 5 dengan fokus praktikal menggunakan teknologi modern, open source, dan integrasi GitHub Education / GitHub Classroom dengan penilaian bertahap (incremental milestones).

Dosen: Yuda Munarko

Filosofi dan Pendekatan

Mengapa Bukan Hadoop/Spark?

Hadoop MapReduce sudah menjadi legacy technology. Dalam industri modern (2025–2026), terjadi pergeseran besar ke paradigma "single-node renaissance" — di mana satu mesin modern (multi-core CPU, SSD NVMe, RAM besar) mampu memproses data skala terabyte tanpa kompleksitas cluster.

Aspek	Hadoop/Spark	Stack Modern (DuckDB/Polars)
Setup	Cluster, JVM tuning, config rumit	<code>pip install</code> atau Docker
Learning curve	Tinggi (HDFS, YARN, Shuffle)	Rendah (Python native)
Kecepatan development	Lambat (deploy ke cluster)	Cepat (local-first)
Relevansi industri 2026	Spark masih ada di perusahaan besar, Hadoop berkurang	Adopsi sangat cepat di startup dan enterprise
Biaya	Mahal (infrastruktur cluster)	Murah (laptop mahasiswa cukup)

Tech Stack dan Infrastruktur Kuliah

Core Tools

Tool	Peran	Platform	Alasan Dipilih
GitHub Classroom	Pengumpulan dan CI/CD Tugas	Cloud	Tracking commit history bertahap, autograding
Wayground	Kuis Interaktif (Instructor-Paced)	Web	Evaluasi pemahaman real-time per segmen materi
Python 3.12+	Bahasa utama	Docker	Standar industri data
Polars	DataFrame engine	Docker	10-100x lebih cepat dari Pandas, lazy evaluation
DuckDB	SQL analytics engine	Docker	Query file Parquet/CSV langsung, tanpa server

Tool	Peran	Platform	Alasan Dipilih
Plotly / Altair	Visualisasi interaktif	Docker	Modern, interaktif, web-ready
Streamlit	Dashboard dan data apps	HF Spaces	Rapid prototyping, industri-ready deployment
Dask	Parallel computing	Docker	Pure Python parallel processing
HuggingFace Spaces	Hosting Data Product	Cloud	Free cloud deployment untuk Streamlit apps

Format Kuis Interaktif Wayground (Instructor-Paced Mode)

Untuk menjaga keterlibatan dan mengevaluasi pemahaman secara real-time, 10 soal kuis pada setiap pertemuan **tidak diberikan sekaligus di akhir**, melainkan dibagi menjadi 3 Checkpoint Interaktif selama 90 menit perkuliahan menggunakan **Wayground Instructor-Paced Mode**:

- **Checkpoint 1 (Menit 25 - Setelah Pembahasan Teori Dasar):** 3 Soal Konseptual.
- **Checkpoint 2 (Menit 55 - Setelah Pembahasan Teknikal/Kode):** 3 Soal Praktikal / Analisis Kode.
- **Checkpoint 3 (Menit 85 - Setelah Hands-on Lab):** 4 Soal Sintesis / Critical Thinking.

Prinsip Penyusunan Soal Kuis Wayground:

1. **Keseimbangan Panjang Opsi:** Panjang kalimat seluruh pilihan jawaban (a, b, c, d) disetarakan untuk menghindari pola di mana opsi benar cenderung paling panjang.
2. **Distribusi Kunci Jawaban:** Kunci jawaban tersebar secara merata antar opsi (a, b, c, d).
3. **Kombinasi Tingkat Kesulitan:** 4 soal konseptual dasar, 4 soal praktikal/kode, dan 2 soal sintesis/critical thinking.

Rencana 12 Pertemuan dan Milestone Tugas

Pertemuan 1: Pengantar Big Data dan Ekosistem Modern

- Teori (20 menit): 5V Big Data, Evolusi Hadoop ke Spark ke Single-Node Renaissance.
- Wayground Checkpoint 1 (5 menit): 3 Soal Konseptual Big Data.
- Teori dan Demo (25 menit): Setup Docker, Polars vs Pandas, Parquet vs CSV.
- Wayground Checkpoint 2 (5 menit): 3 Soal Tools dan Format Data.
- Praktik Lab (30 menit): Hands-on benchmark Polars vs Pandas pada 1 juta baris.
- Wayground Checkpoint 3 (5 menit): 4 Soal Sintesis dan Hasil Benchmark.

Pertemuan 2: Python untuk Big Data — Polars Deep Dive

- Teori (20 menit): Arsitektur Polars (Rust dan Apache Arrow), Lazy vs Eager evaluation.
- Wayground Checkpoint 1 (5 menit): 3 Soal Konseptual Polars API.
- Teori dan Demo (25 menit): Expressions, chaining methods, `scan_csv()`.
- Wayground Checkpoint 2 (5 menit): 3 Soal Kode Polars Expressions.
- Praktik Lab (30 menit): Hands-on Polars pada data BPS. Pengumuman Tugas 1 (Milestone 1).

- Wayground Checkpoint 3 (5 menit): 4 Soal Optimasi Query Polars.
-

Pertemuan 3: SQL untuk Big Data — DuckDB dan Format Data

- Teori (20 menit): DuckDB in-process OLAP, Apache Arrow zero-copy, Partitioning.
 - Wayground Checkpoint 1 (5 menit): 3 Soal Konseptual OLAP dan DuckDB.
 - Teori dan Demo (25 menit): Query Parquet/CSV langsung, JupySQL, Predicate Pushdown.
 - Wayground Checkpoint 2 (5 menit): 3 Soal SQL DuckDB dan Window Functions.
 - Praktik Lab (30 menit): Hands-on DuckDB query data Satu Data Indonesia. Check-in Milestone 1.
 - Wayground Checkpoint 3 (5 menit): 4 Soal Interoperabilitas DuckDB dan Polars.
-

Pertemuan 4: Data Cleaning dan Quality di Skala Besar

- Teori (20 menit): Data Quality Dimensions, Profiling, Great Expectations.
 - Wayground Checkpoint 1 (5 menit): 3 Soal Konseptual Data Quality.
 - Teori dan Demo (25 menit): Profiling DuckDB **SUMMARIZE**, handling nulls/outliers di Polars.
 - Wayground Checkpoint 2 (5 menit): 3 Soal Teknik Cleaning dan Validation Rules.
 - Praktik Lab (30 menit): Cleaning dataset e-commerce Indonesia.
 - Wayground Checkpoint 3 (5 menit): 4 Soal Kasus Data Anomali.
-

Pertemuan 5: Exploratory Data Analysis (EDA) dan Visualisasi Interaktif

- Teori (20 menit): Prinsip EDA Big Data, Grammar of Graphics (Plotly / Altair).
 - Wayground Checkpoint 1 (5 menit): 3 Soal Konseptual EDA dan Visualisasi.
 - Teori dan Demo (25 menit): Pipeline DuckDB aggregate ke Polars transform ke Plotly.
 - Wayground Checkpoint 2 (5 menit): 3 Soal Pemilihan Chart dan Interaktivitas.
 - Praktik Lab (30 menit): EDA dataset e-commerce + Peta Indonesia. Check-in Milestone 2.
 - Wayground Checkpoint 3 (5 menit): 4 Soal Interpretasi Visualisasi.
-

Pertemuan 6: Pemrosesan Data Time Series Besar

- Teori (20 menit): Karakteristik Time Series, Resampling, Rolling windows, Partitioning.
 - Wayground Checkpoint 1 (5 menit): 3 Soal Konseptual Time Series.
 - Teori dan Demo (25 menit): Polars **group_by_dynamic()**, **rolling()**.
 - Wayground Checkpoint 2 (5 menit): 3 Soal Kode Windowing Temporal.
 - Praktik Lab (30 menit): Analisis cuaca BMKG. Pengumuman Tugas 2 (Phase 1).
 - Wayground Checkpoint 3 (5 menit): 4 Soal Desain Fitur Temporal.
-

Pertemuan 7: Komputasi Paralel dan Distributed — Dask

- Teori (20 menit): Arsitektur Dask (Task Graph, Scheduler, Workers), Dask vs Spark.
- Wayground Checkpoint 1 (5 menit): 3 Soal Konseptual Parallel Computing.
- Teori dan Demo (25 menit): Dask DataFrame dan Delayed, Dask Dashboard.
- Wayground Checkpoint 2 (5 menit): 3 Soal Kode Dask dan Lazy Execution.
- Praktik Lab (30 menit): Pemrosesan multi-file Parquet. Check-in Tugas 2 Phase 1.

- Wayground Checkpoint 3 (5 menit): 4 Soal Trade-off Single-Node vs Distributed.
-

Pertemuan 8: Analisis Teks (NLP) pada Data Besar

- Teori (20 menit): NLP Pipeline, TF-IDF, HuggingFace Ecosystem dan IndoNLU.
 - Wayground Checkpoint 1 (5 menit): 3 Soal Konseptual NLP dan Text Representations.
 - Teori dan Demo (25 menit): Preprocessing teks dengan Polars, model HuggingFace.
 - Wayground Checkpoint 2 (5 menit): 3 Soal Kode Text Processing Polars dan Transformers.
 - Praktik Lab (30 menit): Sentimen analisis review produk Tokopedia/Shopee. Check-in Milestone 3.
 - Wayground Checkpoint 3 (5 menit): 4 Soal Evaluasi Model Sentimen.
-

Pertemuan 9: Machine Learning pada Big Data

- Teori (20 menit): Tantangan ML pada Big Data (OOM, waktu training), Scikit-learn Pipeline.
 - Wayground Checkpoint 1 (5 menit): 3 Soal Konseptual Scalable ML.
 - Teori dan Demo (25 menit): Feature engineering Polars, Random Forest / Gradient Boosting.
 - Wayground Checkpoint 2 (5 menit): 3 Soal Kode Pipeline Scikit-learn.
 - Praktik Lab (30 menit): Prediksi harga/demand e-commerce. Check-in Tugas 2 Phase 2.
 - Wayground Checkpoint 3 (5 menit): 4 Soal Evaluasi dan Feature Importance.
-

Pertemuan 10: Membangun Dashboard Data — Streamlit

- Teori (20 menit): Reactive Frameworks, Arsitektur Streamlit, Caching (`@st.cache_data`).
 - Wayground Checkpoint 1 (5 menit): 3 Soal Konseptual Web Data Apps.
 - Teori dan Demo (25 menit): Streamlit widgets, DuckDB backend, HF Spaces deployment.
 - Wayground Checkpoint 2 (5 menit): 3 Soal Kode Streamlit Caching dan Widgets.
 - Praktik Lab (30 menit): Build dashboard interaktif. Final Submission Tugas 1 & Check-in Tugas 2 Phase 3.
 - Wayground Checkpoint 3 (5 menit): 4 Soal Optimasi Performa Dashboard.
-

Pertemuan 11: Data Pipeline dan Orkestrasi

- Teori (20 menit): ETL vs ELT, Containerization Docker, GitHub Actions CI/CD.
 - Wayground Checkpoint 1 (5 menit): 3 Soal Konseptual Data Pipelines.
 - Teori dan Demo (25 menit): Automasi script Python, Dockerization pipeline.
 - Wayground Checkpoint 2 (5 menit): 3 Soal Kode Dockerfile dan Pipeline Scripts.
 - Praktik Lab (30 menit): End-to-end pipeline automation.
 - Wayground Checkpoint 3 (5 menit): 4 Soal Troubleshooting Pipelines.
-

Pertemuan 12: Presentasi Data Product dan Tren Industri

- Teori dan Karir (20 menit): Landscape Karir Data 2026, Data Ethics, UU PDP.
- Wayground Checkpoint 1 (5 menit): 3 Soal Etika Data dan Regulasi.
- Presentasi Tim (25 menit): Demo live Streamlit App di HuggingFace Spaces.
- Wayground Checkpoint 2 (5 menit): 3 Soal Komprehensif Architecture.

- Feedback dan Diskusi (30 menit): Peer review dan arahan lanjutan.
 - Wayground Checkpoint 3 (5 menit): 4 Soal Komprehensif Synthesis.
-

Contoh Soal Kuis Wayground (Pertemuan 1 - Opsi Seimbang)

Checkpoint 1: Konsep Big Data

1. Manakah yang bukan merupakan karakteristik utama Big Data dalam kerangka 5V?
 - a) Volume data yang terus berkembang secara cepat.
 - b) Velocity kecepatan aliran data masuk dan diproses.
 - c) Visualization teknik pembuatan chart dan grafik.
 - d) Veracity tingkat keandalan serta kualitas data.
 - Kunci: c (Opsi disetarakan panjangnya).
2. Apa alasan utama industri modern mulai beralih ke paradigma single-node renaissance?
 - a) Harga server cluster menjadi jauh lebih mahal dibanding tahun sebelumnya.
 - b) Mesin tunggal modern dengan SSD NVMe dan multi-core mampu mengolah data terabyte.
 - c) Hadoop dan Spark sudah tidak didukung lagi oleh komunitas open source global.
 - d) Bahasa Python tidak dapat dijalankan di dalam lingkungan distributed cluster.
 - Kunci: b (Opsi disetarakan panjangnya).
3. Manakah fungsi utama dari Apache Arrow dalam infrastruktur pengolahan data modern?
 - a) Menyimpan data secara permanen di dalam sistem penyimpanan awan lokal.
 - b) Menyediakan antarmuka grafis pengguna untuk menjalankan query SQL analitik.
 - c) Menjadi format data in-memory columnar untuk pertukaran data zero-copy antar alat.
 - d) Mengatur jadwal eksekusi tugas paralel di dalam lingkungan distributed cluster.
 - Kunci: c (Opsi disetarakan panjangnya).

Checkpoint 2: Tools dan Format Data

4. Mengapa format file Parquet jauh lebih disukai dibanding CSV untuk pengolahan Big Data?
 - a) Parquet dapat dibuka secara langsung menggunakan aplikasi teks editor standar.
 - b) Parquet menggunakan struktur berbasis baris yang mempermudah pembacaan manual.
 - c) Parquet menyimpan data secara columnar, mendukung kompresi dan predicate pushdown.
 - d) Parquet hanya dapat digunakan pada sistem operasi Linux dan tidak pada Windows.
 - Kunci: c (Opsi disetarakan panjangnya).
5. Perbedaan mendasar antara DuckDB dan sistem database OLTP tradisional seperti MySQL adalah...
 - a) DuckDB dirancang khusus untuk query analitik in-process dengan penyimpanan columnar.
 - b) DuckDB membutuhkan server terpisah yang harus dikonfigurasi sebelum query dijalankan.
 - c) MySQL lebih cepat dalam menangani query agregasi pada data berukuran jutaan baris.
 - d) DuckDB tidak mendukung perintah standar SQL seperti SELECT, WHERE, dan GROUP BY.
 - Kunci: a (Opsi disetarakan panjangnya).

6. Polars mampu mencapai kecepatan yang jauh lebih tinggi dibanding Pandas terutama karena...

- a) Polars ditulis menggunakan bahasa Java yang berjalan di dalam Java Virtual Machine.
- b) Polars mengeksekusi perintah secara multi-threaded dan berbasis pada memori Apache Arrow.
- c) Polars secara otomatis memindahkan seluruh proses perhitungan ke dalam Graphics Processing Unit.
- d) Polars hanya mendukung tipe data angka dan tidak dapat mengolah tipe data teks.
- Kunci: b (Opsi disetarakan panjangnya).

Checkpoint 3: Sintesis dan Benchmark

7. Ketika Anda memanggil perintah `scan_csv()` pada Polars, apa yang sebenarnya terjadi?

- a) Seluruh file CSV langsung dibaca ke dalam memori RAM komputer secara utuh.
- b) Polars membuat objek LazyFrame yang menunda eksekusi hingga metode collect dipanggil.
- c) File CSV otomatis dikonversi menjadi file database DuckDB di dalam disk lokal.
- d) Perintah tersebut langsung menghasilkan error jika ukuran file melebihi 1 Gigabyte.
- Kunci: b (Opsi disetarakan panjangnya).

8. Fitur predicate pushdown pada DuckDB memberikan manfaat berupa...

- a) Memastikan bahwa semua kolom data dibaca sepenuhnya sebelum query dijalankan.
- b) Mengubah semua tipe data teks menjadi bentuk angka secara otomatis saat query.
- c) Mengurangi volume data yang dibaca dari disk dengan memfilter data di tingkat file.
- d) Menggabungkan beberapa tabel sekaligus tanpa perlu menentukan kunci pencocokan.
- Kunci: c (Opsi disetarakan panjangnya).

9. Peran Docker dalam ekosistem perkuliahan ini adalah untuk...

- a) Mempercepat waktu eksekusi query SQL pada database DuckDB secara signifikan.
- b) Menyediakan lingkungan eksekusi yang seragam, konsisten, dan mudah direproduksi.
- c) Menggantikan fungsi repositori GitHub Classroom dalam pengumpulan tugas kuliah.
- d) Menyimpan dataset berukuran besar di dalam server cloud secara otomatis tanpa biaya.
- Kunci: b (Opsi disetarakan panjangnya).

10. Jika Anda perlu menganalisis dataset 20 Gigabyte di laptop dengan RAM 16 Gigabyte, pendekatan terbaik adalah...

- a) Membaca seluruh data menggunakan Pandas read_csv secara langsung ke memori RAM.
- b) Membagi data menjadi 100 file kecil lalu membacanya satu per satu menggunakan Excel.
- c) Menggunakan Polars lazy evaluation atau DuckDB query langsung ke file Parquet.
- d) Menghapus setengah dari baris data secara acak agar muat di dalam memori RAM.
- Kunci: c (Opsi disetarakan panjangnya).

Struktur Penilaian

Komponen	Bobot	Detail Penilaian
Kuis Wayground (12×)	20%	Evaluasi interaktif 3 checkpoint per pertemuan
Tugas 1 (Individual)	25%	Dievaluasi dari 4 Milestone Commit di GitHub Classroom
Tugas 2 (Kelompok)	35%	Dievaluasi dari 3 Phase Check-in, HF Space Live, Video Demo, dan Presentasi
Partisipasi dan Code Reviews	20%	Keaktifan di kelas dan Pull Request review antar mahasiswa

Nilai Kelulusan

60 <=