

Spesifikasi Tugas — Kuliah Analisis Big Data

Integrasi GitHub Education dan GitHub Classroom

Seluruh tugas dalam perkuliahan ini dikelola melalui GitHub Classroom (bagian dari program GitHub Education).

Ketentuan untuk Mahasiswa:

- 1. **GitHub Student Developer Pack:** Mahasiswa wajib mengaktifkan akun GitHub Student Developer Pack untuk mendapatkan akses fitur pro.
- 2. **Autograding dan CI/CD:** Setiap push ke repository akan memicu pemeriksaan otomatis (formatting, linting, serta pengujian script data loading).
- 3. **Commit History Tracking:** Penilaian berbasis pada rekam jejak commit yang konsisten sepanjang semester untuk menunjukkan proses belajar.

Tugas 1: Eksplorasi dan Analisis Dataset Besar Indonesia (Incremental Individual Project)

Informasi Umum

Item	Detail
Tipe	Individual
Diumumkan	Pertemuan 2
Platform	GitHub Classroom
Bobot	25% dari nilai akhir

Skema Tahapan (Incremental Milestones)

Milestone	Diberikan	Target Check-in (Commit Deadline)	Deliverable
Milestone 1	Pertemuan 2	Pertemuan 3	Repository Setup dan Data Acquisition: Clone repo GitHub Classroom, buat <code>data/README.md</code> dengan skrip instruksi pengunduhan data, sertakan notebook profiling awal dataset (>500MB / >1M baris).
Milestone 2	Pertemuan 4	Pertemuan 5	Data Quality dan Profiling: Implementasi DuckDB <code>SUMMARIZE</code> dan transformasi Polars untuk data cleaning, penanganan missing values dan outliers, validasi data dasar.
Milestone 3	Pertemuan 6	Pertemuan 8	Time Series dan Advanced EDA: Pemrosesan pola temporal/ruang (Polars temporal/window functions), minimal 6 visualisasi interaktif Plotly/Altair.
Final Submission	Pertemuan 8	Pertemuan 10	Final Polish dan Docker: Penulisan 5+ insight utama, pembungkusan environment dengan Dockerfile, pengerjaan <code>README.md</code> akhir.

Persyaratan Teknis

Dataset

- Minimal 500MB atau >1 juta baris.
- Sumber dataset yang diperbolehkan: BPS Web API, Satu Data Indonesia, BMKG Data Online, HuggingFace Datasets, Kaggle Indonesia.

Tools Wajib

- Polars untuk data manipulation (bukan Pandas).
- DuckDB untuk SQL analytics.
- Plotly atau Altair untuk visualisasi.
- JupyterLab sebagai environment.

Struktur Repository GitHub Classroom

```
tugas1-[username_github]/
├── .github/
│   └── workflows/
│       └── lint_check.yml    # GitHub Actions (Autograding)
├── README.md                # Laporan utama dan AI Disclosure Statement
├── Dockerfile                # Untuk reproduktivitas
├── requirements.txt          # Dependencies Python
├── notebooks/
│   ├── 01_data_profiling.ipynb
│   ├── 02_data_cleaning.ipynb
│   └── 03_eda_and_insights.ipynb
├── src/                      # Helper scripts / module Polars
├── data/
│   └── README.md             # Petunjuk download data
└── output/
    └── figures/              # Visualisasi ter-export
```

Rubrik Penilaian Tugas 1 (Skala 5 Tingkat)

Kriteria Penilaian	Bobot	Teladan ($\geq 80\%$)	Mahir (70– $<80\%$)	Kompeten (55– $<70\%$)	Berkembang (40– $<55\%$)	Tidak Memuaskan ($< 40\%$)
Konsistensi Commit & GitHub Workflow	20%	Commit bertahap di tiap milestone secara teratur; pesan commit deskriptif & konvensional; mematuhi struktur folder dan lulus autograding.	Commit ada di sebagian besar milestone; pesan commit jelas; autograding lulus dengan perbaikan minor.	Commit hanya 2-3 kali menjelang deadline; pesan commit kurang deskriptif; sebagian autograding belum lolos.	Commit menumpuk dalam 1 hari terakhir menjelang batas waktu; struktur repositori tidak rapi.	Hanya 1 commit akhir (indikasi joki/copy-paste); mengabaikan alur GitHub Classroom.
Data Handling (Polars & DuckDB)	25%	Menggunakan Polars LazyFrame expressions & DuckDB query secara optimal; dataset >1 juta baris; eksekusi hemat memori dan cepat.	Polars dan DuckDB digunakan dengan benar; dataset 500K–1M baris; eksekusi lancar meski ada sedikit operasi eager.	Menggunakan Polars/DuckDB dasar namun masih bercampur dengan sintaks Pandas; dataset <500 K baris.	Sebagian besar pemrosesan memakai Pandas biasa; efisiensi memori rendah.	Hanya menggunakan Pandas konvensional; dataset sangat kecil (<100 K baris) atau script error.
Cleaning & Data Quality	15%	Profiling lengkap dengan DuckDB <code>SUMMARIZE</code> ; aturan validasi data otomatis; penanganan null/outlier terdokumentasi rapi.	Pembersihan data terstruktur dengan Polars; penanganan anomali baik; dokumentasi cukup jelas.	Pembersihan data dilakukan secara manual/ sederhana; dokumentasi penanganan anomali minim.	Pembersihan data tidak tuntas; masih menyisakan banyak nilai anomali tanpa penjelasan.	Data mentah tidak dibersihkan sama sekali; tidak ada tahapan data quality.
Visualisasi & Data Insights	25%	>8 visualisasi interaktif (Plotly/Altair) yang informatif dan estetik; >5 wawasan bisnis/analitik mendalam; alur storytelling logis.	6–8 visualisasi interaktif; 3–4 wawasan analitik jelas dan relevan.	4–5 visualisasi standar; wawasan data masih bersifat permukaan/deskriptif umum.	Visualisasi minim atau statis; interpretasi data kurang akurat.	Visualisasi tidak berfungsi, terdistorsi, atau tidak menyajikan wawasan apa pun.
Reproduktivitas & Docker	15%	<code>Dockerfile</code> berhasil dibangun dan dijalankan tanpa error; <code>requirements.txt</code> presisi; <code>README.md</code> sangat instruktif dan jelas.	<code>Dockerfile</code> dan environment berjalan dengan instruksi yang baik; dokumentasi	<code>Dockerfile</code> ada namun membutuhkan perbaikan manual saat build; <code>README.md</code> singkat.	Tanpa <code>Dockerfile</code> atau kontainer gagal dibangun total; dokumentasi sulit diikuti.	Repositori tidak dapat direproduksi dan tidak ada petunjuk instalasi.

Kriteria Penilaian	Bobot	Teladan ($\geq 80\%$)	Mahir (70– $<80\%$)	Kompeten (55– $<70\%$)	Berkembang (40– $<55\%$)	Tidak Memuaskan ($< 40\%$)
			cukup lengkap.			

Tugas 2: Data Product — Dashboard Analitik Interaktif (Incremental Team Project)

Informasi Umum

Item	Detail
Tipe	Kelompok (2-3 orang)
Diumumkan	Pertemuan 6
Deadline	Pertemuan 12 + 1 minggu
Platform	GitHub Classroom Team dan HuggingFace Spaces
Bobot	35% dari nilai akhir

Skema Tahapan (Incremental Milestones)

Milestone	Diberikan	Target Check-in	Deliverable
Phase 1: Pitch dan Architecture	Pertemuan 6	Pertemuan 7	Pembentukan tim di GitHub Classroom, pengajuan proposal topik dan skema arsitektur data di <code>docs/architecture.md</code> .
Phase 2: Data Pipeline dan Query Engine	Pertemuan 8	Pertemuan 9	Integrasi DuckDB/Polars backend, skrip ekstraksi data dan caching siap dipakai Streamlit.
Phase 3: Streamlit UI dan HF Space Staging	Pertemuan 10	Pertemuan 11	Prototype dashboard live di HuggingFace Spaces (staging), pengujian interaktivitas widget dan chart.
Final Release dan Presentation	Pertemuan 11	Pertemuan 12+1w	Final deployment, video demo 3-5 menit, penyelesaian laporan dan presentasi.

Rubrik Penilaian Tugas 2 (Skala 5 Tingkat)

Kriteria Penilaian	Bobot	Teladan ($\geq 80\%$)	Mahir (70– $<80\%$)	Kompeten (55– $<70\%$)	Berkembang (40– $<55\%$)	Tidak Memuaskan ($< 40\%$)
Kolaborasi GitHub & Milestones	15%	Kontribusi merata antar anggota tim terbukti via Pull Requests & code review; commit berkala di setiap milestone fase.	Kontribusi aktif dari semua anggota; commit berkala di sebagian besar milestone.	Kontribusi anggota kurang seimbang; riwayat commit terkonsentrasi di akhir fase.	Dominasi satu anggota tim; minim interaksi PR/review di GitHub.	Tidak ada jejak kerja sama tim di GitHub; commit hanya dilakukan satu orang di menit akhir.
Fungsionalitas & Arsitektur	20%	Aplikasi web reaktif Streamlit sangat responsif; backend DuckDB/Polars cepat dan modular; arsitektur bersih tanpa <i>bug</i> .	Aplikasi berjalan stabil dengan sedikit latensi saat manipulasi filter; fitur utama berfungsi baik.	Beberapa fitur mengalami <i>minor bug</i> saat pergantian filter widget; arsitektur kode kurang modular.	Aplikasi sering lambat atau terjadi <i>warning error</i> pada antarmuka pengguna.	Aplikasi mengalami <i>crash</i> total; arsitektur tidak sesuai spesifikasi.
Data Engineering & Caching	20%	Penerapan caching <code>@st.cache_data</code> & <code>@st.cache_resource</code> optimal; lazy loading berjalan mulus pada data $>1\text{M}$ baris.	Caching diterapkan pada kueri utama; data 500K–1M baris terload dengan lancar.	Caching dasar diimplementasikan namun masih terjadi reload data redundan; ukuran data sedang.	Caching tidak diimplementasikan sehingga setiap aksi memicu reload data dari awal yang lambat.	Tidak efisien; konsumsi memori ekstrem dan menyebabkan <i>server out-of-memory</i> .
Visualisasi & User Experience (UX)	20%	Visualisasi Plotly/Altair kaya filter dan interaktif; tata letak antarmuka intuitif, konsisten, dan berstandar industri.	Antarmuka rapi; visualisasi interaktif dan mudah dibaca oleh pengguna awam.	Tampilan cukup rapi namun visualisasi standar; navigasi antarmuka agak kaku.	Tata letak antarmuka berantakan; grafik visualisasi terdistorsi atau sulit diinterpretasi.	Tampilan tidak tertata; visualisasi rusak atau tidak komunikatif.
Live Deployment, Video & Presentasi	25%	Live App di HuggingFace Spaces stabil & cepat; video demo 3–5 menit sangat profesional; presentasi tim meyakinkan & solutif.	Live App di HuggingFace Spaces berjalan baik; video demo dan presentasi jelas serta terstruktur.	Live App berjalan dengan performa pas-pasan; video demo dan presentasi bersifat standar.	Live App gagal dideploy ke cloud (hanya berjalan di localhost); video demo belum selesai.	Tidak ada aplikasi yang dideploy; tidak mengumpulkan video demo dan tidak hadir presentasi.