

Pengantar Big Data dan Ekosistem Modern

Pertemuan 1 — Analisis Big Data

S1 Teknik Informatika / Sistem Informasi | Semester Ganjil 2026

Agenda Pertemuan 1

1. Apa itu Big Data? Framework 5V
2. Evolusi teknologi: Hadoop, Spark, ke Single-Node Renaissance
3. Ekosistem tools kuliah ini
4. Format data: CSV vs Parquet
5. Docker: lingkungan yang konsisten
6. Hello World: DuckDB dan Polars
7. Benchmark Pandas vs Polars


Kuis Wayground: 3 Checkpoint (Menit 25, 55, 85)

Apa itu Big Data?

Data dianggap **Big Data** ketika melampaui kemampuan pemrosesan konvensional pada setidaknya satu dimensi berikut:

Dimensi (V)	Definisi	Contoh
Volume	Ukuran data sangat besar	Miliaran transaksi e-commerce
Velocity	Kecepatan data masuk tinggi	Stream transaksi perbankan real-time
Variety	Beragam format data	Teks, gambar, JSON, log, sensor
Veracity	Kualitas/keandalan data	Data kotor dari berbagai sumber
Value	Nilai bisnis yang dapat diekstrak	Insight untuk pengambilan keputusan

Evolusi Teknologi Big Data



Mengapa pergeseran terjadi?

- Mesin modern: CPU 64-core, RAM 512GB, SSD NVMe 1TB
- Satu laptop mahasiswa cukup untuk memproses data terabyte
- Kompleksitas cluster tidak selalu sebanding hasilnya

Mengapa Bukan Hadoop / Spark?

Stack Lama (Hadoop/Spark)

- Setup cluster JVM yang rumit
- HDFS, YARN, Shuffle tuning
- Learning curve sangat tinggi
- Deploy ke cluster butuh waktu lama
- Biaya infrastruktur mahal
- Hadoop MapReduce sudah legacy

Stack Modern (DuckDB/Polars)

- `pip install polars duckdb`
- Langsung berjalan di laptop
- Learning curve rendah (Python native)
- Eksekusi dalam detik di lokal
- Gratis dan open source
- Adopsi cepat di industri 2025-2026

Catatan: Spark masih relevan untuk data petabyte di perusahaan besar, namun untuk sebagian besar kasus industri, stack modern lebih efisien.

Ekosistem Tools Kuliah Ini

Pemrosesan Data

- Polars
- DuckDB
- PyArrow

Visualisasi

- Plotly Express
- Altair
- Streamlit


Skala & AI

- Dask
- HuggingFace
- Scikit-learn

Semua tools tersedia sebagai **Docker image** yang sudah dikonfigurasi.
Tidak perlu install manual.

```
# Jalankan seluruh environment:  
docker compose up  
# Buka: http://localhost:8888 (JupyterLab)
```

Apache Arrow: Jembatan Antar Tools



- Apache Arrow adalah **format in-memory kolumnar standar**
- Pertukaran data antar tools hampir **zero-copy** (tanpa salin data)
- DuckDB dan Polars dapat berbagi data tanpa konversi

Format Data: CSV vs Parquet

Aspek	CSV	Parquet
Orientasi	Baris (row-based)	Kolom (column-based)
Kompresi	Tidak ada (plain text)	Kompresi otomatis (Snappy, ZSTD)
Ukuran file	Besar	3-10x lebih kecil
Kecepatan baca	Lambat	5-20x lebih cepat
Kolom tertentu	Harus baca semua	Hanya baca kolom yang diperlukan
Tipe data	Tidak ada (inferensi)	Tersimpan dalam schema
Kompatibilitas	Universal (Excel, dll)	Tools analitik (DuckDB, Polars, Spark)

Aturan praktis: Gunakan Parquet untuk penyimpanan dan analitik. Gunakan CSV hanya untuk pertukaran dengan pihak luar yang tidak mendukung Parquet.

Docker: Lingkungan yang Konsisten

Masalah tanpa Docker:

"Di laptopku berjalan, tapi di komputer temanku error..."

Solusi dengan Docker:

```
# Struktur project
bigdata-kuliah/
├── docker-compose.yml  # Konfigurasi container
├── Dockerfile          # Definisi image
├── requirements.txt    # Dependency Python
└── notebooks/         # Folder tutorial
```

Docker memastikan:

- Semua mahasiswa menggunakan **environment yang identik**
- Python version, library version, dan konfigurasi **sama persis**
- Mudah direproduksi oleh dosen, asisten, dan pemeriksa tugas

Hello World: DuckDB dan Polars

DuckDB — SQL Analitik

```
import duckdb

# Query SQL langsung di Python
duckdb.sql("""
    SELECT
        'Hello Big Data!' AS pesan,
        42 AS angka,
        CURRENT_TIMESTAMP AS waktu
""").show()

# Query file Parquet tanpa import!
duckdb.sql("""
    SELECT kota, COUNT(*) AS n
    FROM 'data/transaksi.parquet'
    GROUP BY kota
    ORDER BY n DESC
""").show()
```

Polars — DataFrame Modern

```
import polars as pl

# Buat DataFrame
df = pl.DataFrame({
    "kota": ["Jakarta", "Bandung"],
    "nilai": [92, 87]
})

# Expressions (kolumnar, paralel)
(df
 .filter(pl.col("nilai") > 85)
 .group_by("kota")
 .agg(pl.col("nilai").mean())
)
```

Kuis Checkpoint 1 (Menit 25)

Buka Wayground — Instructor-Paced Mode

3 soal konseptual Big Data:

1. Manakah yang bukan merupakan karakteristik 5V Big Data?
2. Mengapa industri modern beralih ke paradigma single-node renaissance?
3. Apa fungsi utama Apache Arrow dalam ekosistem data modern?

Waktu: 3 menit

Demo: Lazy vs Eager di Polars

Eager (seperti Pandas): Langsung dieksekusi


```
df = pl.read_parquet("transaksi.parquet") # Baca SEMUA ke memori
hasil = df.filter(pl.col("status") == "selesai").group_by("kota").agg(...)
```

Lazy (dioptimalkan): Bangun rencana dulu, eksekusi saat `.collect()`

```
hasil = (
    pl.scan_parquet("transaksi.parquet") # Belum baca file
    .filter(pl.col("status") == "selesai") # Predicate pushdown
    .select(["kota", "harga"]) # Column pruning
    .group_by("kota")
    .agg(pl.col("harga").sum())
    .collect() # BARU baca file di sini
)
```

Predicate pushdown: filter diterapkan saat membaca file, bukan setelahnya.
Hanya baris dan kolom yang dibutuhkan yang dibaca ke memori.

Benchmark: Pandas vs Polars



Kuis Checkpoint 2 (Menit 55)

Buka Wayground — Instructor-Paced Mode

3 soal tentang Tools dan Format Data:

4. Mengapa format Parquet lebih disukai dibanding CSV untuk analitik Big Data?
5. Apa perbedaan mendasar DuckDB dengan MySQL atau PostgreSQL?
6. Polars mampu jauh lebih cepat dari Pandas terutama karena...

Waktu: 3 menit

Perbandingan Ringkas: Tools Utama

Tool	Peran	Keunggulan Utama
Polars	DataFrame engine	Lazy eval, multi-thread, Arrow native
DuckDB	SQL analytics engine	Query file langsung, OLAP in-process
Plotly	Visualisasi interaktif	Web-ready, zoom, hover, export
Streamlit	Dashboard/data app	Deploy cepat, Python native
Dask	Parallel computing	Out-of-core, multi-node jika perlu
HuggingFace	AI/NLP models	Pre-trained models, datasets gratis

Setup Tugas 1 (Diumumkan Pertemuan 2)

GitHub Classroom sudah terbuka:

1. Aktifkan GitHub Student Developer Pack (gratis)
2. Terima assignment di GitHub Classroom (link akan dibagikan)
3. Clone repository ke Docker container

```
git clone https://classroom.github.com/...  
cd tugas1-username
```

Milestone 1 (deadline Pertemuan 3):

- Setup repository dan akuisisi dataset >500MB

Kuis Checkpoint 3 (Menit 85)

Buka Wayground — Instructor-Paced Mode

4 soal sintesis dan benchmark:

7. Ketika Anda memanggil `scan_csv()` pada Polars, apa yang terjadi?
8. Fitur predicate pushdown pada DuckDB memberikan manfaat berupa...
9. Peran Docker dalam ekosistem perkuliahan ini adalah untuk...
10. Untuk menganalisis dataset 20GB di laptop RAM 16GB, pendekatan terbaik adalah...

Waktu: 4 menit

Ringkasan Pertemuan 1

Hari ini kita telah:

- Memahami konsep Big Data dan framework 5V
- Mengenal paradigma Single-Node Renaissance dan mengapa Hadoop/Spark tidak dipakai
- Berkenalan dengan ekosistem tools: Polars, DuckDB, Arrow, Docker
- Memahami perbedaan CSV vs Parquet
- Menulis kode pertama DuckDB dan Polars
- Menyaksikan benchmark Polars vs Pandas

Pertemuan Berikutnya: Polars Deep Dive — Lazy API, Expressions, Window Functions

Tugas: Persiapkan akun GitHub Student Developer Pack

Referensi

- Janssens, J., & Nieuwdorp, T. (2025). *Python Polars: The Definitive Guide*. O'Reilly Media.
- Needham, M., et al. (2024). *DuckDB in Action*. Manning Publications.
- Polars Documentation: <https://docs.pola.rs/>
- DuckDB Documentation: <https://duckdb.org/docs/>